

2023 AI 허브 데이터 인공지능 해커톤

결과 보고서

■ 기본 정보

팀명	오일남			
팀원정보	성명	소속	연락처	이메일
팀장	이중서	가톨릭대학교 성의교정 의학과	010-3681-1066	jongseo001111@gmail.com
팀원	이현빈	연세대학교 컴퓨터과학과	010-9080-5952	gusqls907@gmail.com

■ AI 모델 설명

AI 모델명	2D Lumbar Spine MRI Axial View를 활용한 요추 추간판 탈출증 예측 모델
활용데이터명	퇴행성 척추질환 진단 및 치료를 위한 멀티모달리티 데이터 퇴행성 요추디스크 질환 (DLD) 데이터 중 MRI 영상 데이터
AI 모델 설명	<div>1) 모델 개요 2D Lumbar Spine MRI Axial View를 활용한 요추 추간판 탈출증 예측 모델</div> <div>2) 모델 개발 목적 저희는 디스크 부분을 촬영한 2D MRI Axial View 이미지 한장만으로 요추 추간판 탈출증이라는 질병을 진단하는 모델 개발을 계획하였습니다.</div> <div>3) 유사 분야 AI와의 차별성 유사 분야 AI의 코드가 공개되어있었던 것이 많지 않았습니다. 주로 MRI 영상에서 요추를 Segmentation 하거나, 척수의 넓이를 측정하여 추간판 탈출증을 진단하거나 Sagittal View에서 진단하는 모델들이 있다는 것을 확인하였고, 해당 논문들을 대회 시작 전에 찾아 읽었습니다. 현재까지 연구되어있는 모델들과의 차별성은 2D 이미지를 3D 이미지로 재구성하지 않고, 2D에서 학습시키고 결과를 얻어 학습이 비교적 빠르게 진행될 수 있다는 점이라고 생각합니다.</div> <div>4) 활용 분야 및 파급 효과 활용 분야 및 효과는 아래 6번 항목에 작성하였습니다.</div>

## AI 모델 개발 방법

### 1) 전처리 방법

저희 팀은 Disc 부분을 촬영한 Spine Mri Axial View 외에도 Lumbar Disk Herniation을 더 정확하게 판별하기 위해서, 환자의 나이, 성별, Mri Axial Ciew에서 척수의 넓이, 이미지 촬영위치 등의 정보를 함께 학습시킬 필요가 있다고 판단하였습니다. 이를 포함한 데이터를 만들기 위해서, 대회 측에서 제공해주신 dcm 파일과, json파일의 정보를 활용하였습니다.

#### • 이미지 처리

대회 측에서 제공해주신 DLD 환자의 데이터에는, 측정방법에 따른 C000 ~ C011까지의 데이터가 있었습니다. 그 중에서 저희는 먼저 요추의 MRI view를 보여주는 C004의 데이터를 사용하였습니다. C004 directory 안에는 T1-weighted Image와 T2-weighted Image의 Axial View, Sagittal View 등 다양한 방식으로 촬영된 이미지가 있었습니다. 그 중에서 저희는 각 파일의 DICOM Tag에 있는 Series Description을 확인하여 T2-weighted Image의 Axial View 이미지를 선별하여 사용하였습니다.

이렇게 선별된 T2 Axial View 이미지의 json파일을 확인하여 L1-2, L2-3 등의 디스크 부분에 증상이 발생하였는지, 하지 않았는지, 혹은 해당사항이 없는지가 1~6의 숫자로 라벨링 되어있는 것을 확인하였습니다. 따라서 저희는 다섯개의 디스크 중 어떤 디스크 부분에서도 촬영되지 않은 이미지를 제외하였습니다.

저희는 결과의 정확도를 위해, 추간판 탈출 증상을 확인할 수 있는 부분에 집중하여 학습시키기로 하였습니다. 조건에 맞는 DICOM파일의 이미지를 상하좌우에서 일정비율 잘라내었습니다. 이미지 크기를 (300, 300)으로 Resize하고, 이미지 픽셀의 Scale을 픽셀의 최대값, 최소값을 이용하여 0~1로 Scaling하여 학습에 활용하였습니다.

#### • Demographic Score 등의 정보처리

저희는 앞서 말씀드렸다시피, MRI Image외에도 환자의 나이, 성별, 척수의 넓이, 이미지 촬영 위치 등의 정보를 함께 활용하여 학습시켰습니다. DICOM 파일의 이름과 대응하는 json파일에 라벨링되어 있는 환자 나이, 성별, 척수넓이를 활용하였습니다. 또, 어떤 디스크에서 찍혔는지에 따라, 척수 넓이 등이 영향을 받을 수 있으므로, L1-2, L2-3, L3-4, L4-5, L5-s1중 어떤 디스크를 촬영한 사진인지를 판단하여 0~4의 이미지 촬영 위치를 추가 정보로 활용하였습니다.

저희는 데이터를 위와 같은 방법으로 전처리하여 model에 들어가는 최종 input 형태를 [[pixel\_array], age, sex, spinal cord width, spinal cord level, is\_patient]로 가공하였습니다.

이와 같은 형태로 대회측에서 제공해주신 데이터를 가공하여 모델을 학습시켰습니다. 대회 측에서 저희한테 제공해주신 데이터는 Train Data와 Validation Data, 크게 이 두 가지로 분류되어 있었습니다. DLD 환자의 MRI axial view에 대해서는 Train Data는 병원 'H01, H02, H03, H04, H06'의 5개 병원에 대한 데이터가 각각 있었지만, Validation Data에는 H01 병원에 대한 데이터만 있었습니다. 병원에서 촬영한 MRI view의 촬영방식이 모두 다르고, 해상도, 명암비, 크기 등의 특징이 모두 달랐습니다. 저희는 보다 일반적인 상황에서의 모델 평가를 진행하고자 했고, 이러한 방식으로 평가된 모델이 더 범용성이 높은 모델이라고 판단했기 때문에 대회 측에서 제

공해주신 Train Data와 Validation Data를 모두 합쳐, 전처리를 진행한 후, 6:2:2 비율로 Train Data, Validation Data, Test Data로 분류하였습니다. 이 과정에서 학습과 평가의 정확도를 위해 Train Data, Validation Data, Test Data의 patient와 non-patient 비율은 전체 데이터 중 patient 와 non-patient 데이터의 비율과 같게 설정하였습니다.

## 2) 모델 네트워크 개요

MyModel(

(cnn): Sequential(

(0): Conv2d(1, 32, kernel\_size=(3, 3), stride=(1, 1), padding=(1, 1))

(1): LeakyReLU(negative\_slope=0.1, inplace=True)

(2): MaxPool2d(kernel\_size=2, stride=2, padding=0, dilation=1, ceil\_mode=False)

(3): Conv2d(32, 64, kernel\_size=(3, 3), stride=(1, 1), padding=(1, 1))

(4): LeakyReLU(negative\_slope=0.1, inplace=True)

(5): MaxPool2d(kernel\_size=2, stride=2, padding=0, dilation=1, ceil\_mode=False)

(6): Conv2d(64, 128, kernel\_size=(3, 3), stride=(1, 1), padding=(1, 1))

(7): LeakyReLU(negative\_slope=0.1, inplace=True)

(8): MaxPool2d(kernel\_size=2, stride=2, padding=0, dilation=1, ceil\_mode=False)

(9): Conv2d(128, 256, kernel\_size=(3, 3), stride=(1, 1), padding=(1, 1))

(10): LeakyReLU(negative\_slope=0.1, inplace=True)

(11): MaxPool2d(kernel\_size=2, stride=2, padding=0, dilation=1, ceil\_mode=False)

(12): Conv2d(256, 512, kernel\_size=(3, 3), stride=(1, 1), padding=(1, 1))

(13): LeakyReLU(negative\_slope=0.1, inplace=True)

(14): MaxPool2d(kernel\_size=2, stride=2, padding=0, dilation=1, ceil\_mode=False)

(15): Flatten()

(16): Linear(in\_features=41472, out\_features=500, bias=True)

(17): LeakyReLU(negative\_slope=0.1, inplace=True)

)

(fcn): Sequential(

(0): Linear(in\_features=4, out\_features=500, bias=True)

(1): ReLU()

)

(fc): Sequential(

(0): Linear(in\_features=1000, out\_features=512, bias=True)

(1): LeakyReLU(negative\_slope=0.1, inplace=True)

(2): Dropout(p=0.1, inplace=False)

(3): Linear(in\_features=512, out\_features=512, bias=True)

```

(4): LeakyReLU(negative_slope=0.1, inplace=True)
(5): Dropout(p=0.1, inplace=False)
(6): Linear(in_features=512, out_features=1, bias=True)
)
)

```

저희가 활용한 학습 모델의 구조 개요는 위와 같으며, 이미지를 처리하는 CNN Network와 그 외 추가 정보들을 처리하는 부분을 합쳐 결과를 도출하는 구조를 이용하였습니다. 이미지를 처리하는 CNN Network를 구성하는 층은 크기 (3 X 3)의 커널을 활용하였으며, padding 을 사용하여 입력 데이터 가장자리 부분의 특징을 보다 잘 보존시키려고 하였습니다. 또한, 활성화 함수로 입력이 음수인 경우 해당 뉴런의 Gradient가 항상 0이 되는 Dying ReLU 문제를 해결한 LeakyReLU를 사용하여 Gradient Flow를 유지하였습니다. Convolutional Layer에서 추출된 특징을 MaxPooling으로 feature map의 크기를 조정하였습니다. 이미지를 처리하는 과정에서는 32개, 64개, 128개, 258개, 512개의 필터를 가진 은닉층들을 거치고, Flatten 연산을 통해 일차원 벡터로 변환하였습니다.

이미지 정보를 제외한, (age, sex, spinal cord width, spinal cord level)등의 환자 정보는 출력뉴런 500 개 짜리 네트워크를 거치고, 앞서 처리한 이미지 출력뉴런 500개와 합쳐져 입력뉴런 1000개가 되도록 구성하였습니다. 이후, 저희가 얻고자 하는 정보가, 0(환자아님), 1(환자)와 같은 이진 정보였기에, 이진 분류 문제에서 주로 사용되는 sigmoid함수를 활용하여 결과를 출력하였습니다.


## 성능 평가 결과

CNN hidden\_layers: 5, kernel\_size: 3, lr = 0.000020, dropout\_p: 0.1, batch\_size: 32

Accuracy: 73.38 %  
 F1 score: 0.7294777232251386  
 AUC: 0.8278793321733057



	<p>저희는 저희가 개발을 한 2D Lumbar Spine MRI Axial View를 활용한 요추 추간판 탈출증 예측 모델에 대해 하이퍼 파라미터를 다양하게 조절하며 성능을 평가하였습니다. 해당 모델의 성능을 평가하기 위해 사용한 지표로는 정확도(Accuracy), F1 Score, AUC (Area Under Curve)가 있습니다. 저희는 해당 모델이 MRI 영상을 입력 데이터로 받기 때문에 검사의 특성상 민감도와 특이도 모두가 중요한 모델이라 생각하였습니다. 따라서, 이 둘을 모두 내재하고 있는 F1-score과 AUC를 확인하였고, 그 중에서도 시각적으로도 쉽게 확인 가능한 ROC curve를 그려, 결론적으로 AUC 증가에 중점을 두고 네트워크의 하이퍼파라미터를 조정하였습니다.</p>
<p><b>개발 결과물의 활용계획</b></p>	<p>1) 개발 결과물의 향후 활용 계획</p> <p>이번 모델에서는 요추의 환자 MRI 영상을 이용하여 2D Lumbar Spine MRI Axial View를 활용한 요추 추간판 탈출증 예측 모델을 개발하였습니다. 이번 대회 결과물을 내기 위해 최선을 다해 임하였지만, 조금 더 기간이 있었다면 모델의 성능을 더 높일 수 있을 것이라는 아쉬움이 조금 남긴 하는 것 같습니다. 이번 모델은 가장 우선적으로, 병원에서 진단 보조도구로 활용할 수 있을 것입니다. 추간판 탈출증에 해당하는 증상을 호소하며 병원에 내원한 환자를 대상으로 MRI까지 촬영을 하였다면, 환자의 진단을 의사가 내리는 과정에서 전보다 빠르고 정확하게 진단을 할 수 있도록 보조할 수 있을 것입니다. 다음으로, 치료 계획수립 지원에도 도움을 줄 수 있을 것입니다. 특정 환자에 대한 기본 정보를 더 추가할 수 있다면, 치료 계획을 환자 개인마다 개별화하여 어렵지 않게 수립할 수 있을 것이라고 생각합니다. 또한 의료데이터에 직접 라벨링을 해본 경험이 있기 때문에, 이가 정말 힘든 작업임을 알고 있습니다. 저희가 개발한 모델을 조금 수정하여 의료 데이터베이스 자체를 확장하고 개선하는 데에도 사용할 수 있을 것이라 생각합니다. 데이터가 정말 소중한 자산으로 여겨지는 요즘 시대에 데이터셋을 가공하고 확장할 수 있는 것만으로도 큰 가치를 가진다고 생각합니다. 또한, 아직 MRI 영상의 세밀한 차이를 분석에 어려움을 느끼는 의학적 학생들을 위하여 의료 교육에도 적용할 수 있을 것이라 생각합니다. 또한 추간판 탈출증 환자 분류하는 것만으로도 의학 논문 작성 및 임상 시험에서 환자를 선별하는 등 적극적으로 적용한다면, 의사의 부담을 줄여줄 수 있을 것이라고 기대합니다.</p> <p>2) 활용 분야, 효과성, 효율성, 파급효과</p> <p>처음 저희가 계획했던 모델은 요추 MRI 모델에서 Disc 부분을 Segmentation 한 후, 디스크에서 Annulus fibrosis의 두께 대표값(평균, 표준편차, 최소값), 전체 디스크 넓이 중 Nucleus Pulposus 넓이의 분율 그리고 척수와 근접하여 직접 압박을 가할 수 있는 위험부위의 두께를 구하여 정상군에서 추간판 탈출증의 위험도를 예측하는 모델을 만드는 것이었습니다. 이를 계획서에 작성해서 제출하였습니다. 하지만, 계획했던 모델을 만들기 위해서는 디스크(추간판)에 직접 라벨링을 전체 또는 일부에 해서 학습을 시킬 필요가 있었는데, 이는 시간상 제약이 크게 다가와 진행하지 못하였습니다. 따라서, 저희는 이번 갖춰진 환경 내에서는 환자와 정상군을 구분하는 모델을 작성하기로 하였고, 후에 이 모델의 결과물을 이용하여 추가로 데이터에 추간판만 라벨링을 할 수 있다면, 기존의 계획대로 모델을 심화해서 개발하여 응용할 수 있을 것이라 생각하였습니다.</p>



Lateral view

Superior view

사전 조사를 해보았을 때, 아직 증상이 발생하지 않은 고위험군 또는 정상군에서 의학적으로 Nucleus Pulposus의 분율을 계산하여 이를 적용하여 환자의 예방을 돕는 연구 또는 치료가 전무하였습니다. 따라서 저희는 계획했던 모델을 완료하여 개발할 수 있다면, 증상이 발생하지 않은 정상군에서 추간판 탈출증이 발생할 가능성이 높은 고위험군을 조사하고 고위험군에서도 경과를 수치화할 수 있는 새로운 지평을 열 수 있을 것이라 기대합니다. 이는 경제적으로도, 의료적으로도 정말 큰 발전을 가져올 수 있을 것이라 생각합니다. 이번 대회에서 받았던 데이터의 양과 질이 우수했었기 때문에, 적극적으로 연구할 수 있다면, 정말 다양하고 생산적인 모델들을 만들 수 있을 것이라 생각하였습니다. 경연대회라는 특성으로 인해 이 부분에 집중할 시간은 부족했으나, 저희 팀은 대회 이후에도 위 내용을 공부하고, 모델에 적용하여 더욱 발전시키고자 합니다. 좋은 기회 주셔서 정말 주최측에 감사하다는 말로 보고서 맺습니다.